Introduction

Cyril Rabat
cyril.rabat@univ-reims.fr

Licence 3 Informatique - Info0602 - Langages et compilation

2021-2022

Cours n°1

Qu'est-ce qu'un compilateur ?
Les phases de la compilation

Version 13 décembre 2021

Table des matières

Un compilateur

Définition : un compilateur

*Programme qui lit un programme écrit dans un premier langage (le **langage source**) et le traduit en un programme équivalent écrit dans un autre langage (le **langage cible**).*

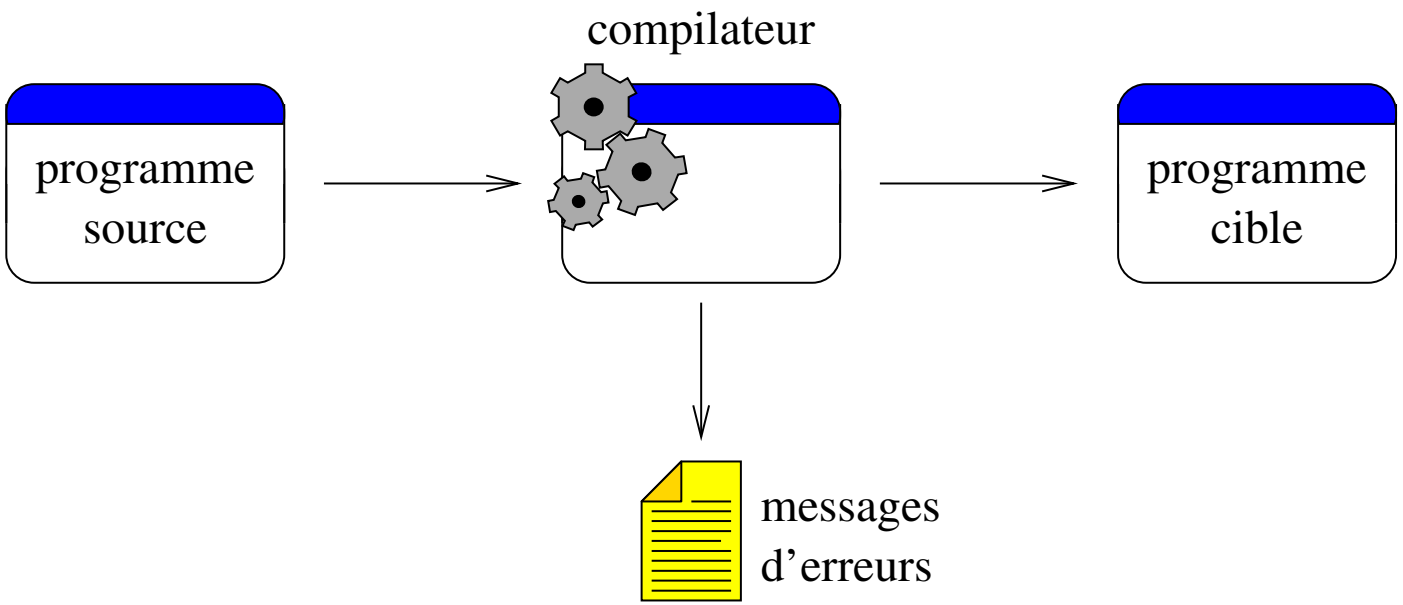

Les concepts

- La compilation fait appel à :
  - La théorie des langages
  - L'architecture des machines
  - L'algorithmique
  - Le génie logiciel
- Ces concepts sont utilisés dans bien d'autres domaines :
  - Le traitement de texte
  - L'interpréteur de commandes / requêtes

Les phases d'un compilateur

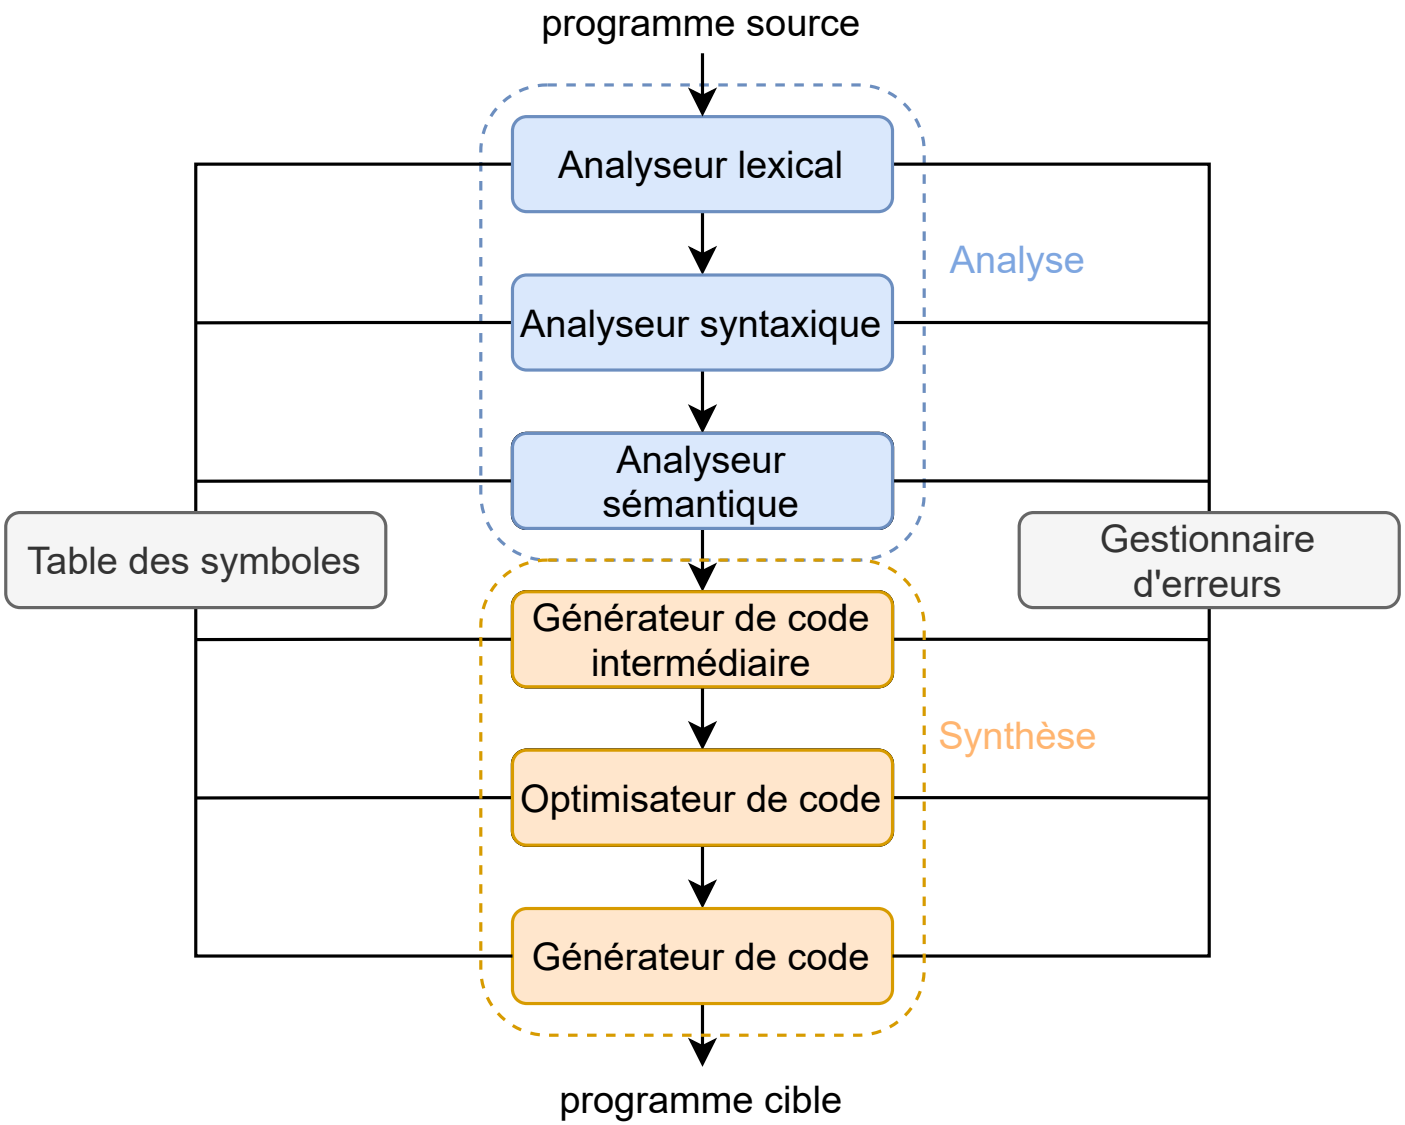

Les deux parties de la compilation

Définition : analyse

- *Partitionnement du programme source en constituants*
- *Création d'une représentation intermédiaire*

Définition : synthèse

- *Construction du programme cible à partir de la représentation intermédiaire*

La représentation intermédiaire

- Pendant l'analyse, les opérations du programme source sont récupérées et conservées
- Pour cela, on utilise une structure hiérarchique : les arbres
- Exemple d'arbre utilisé : l'arbre abstrait

Exemple

- Instruction : $x = a * 2 + b/3$

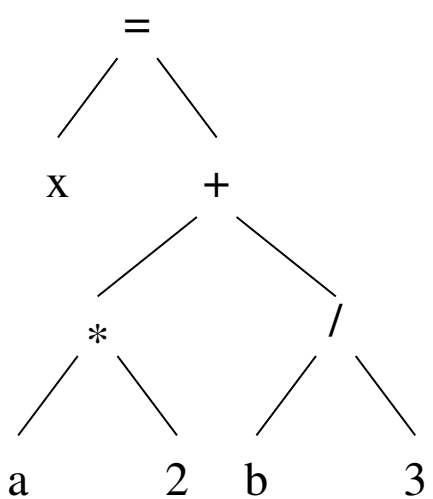

Environnement du compilateur

- Pour créer le programme cible :
  ↪ Compilateur + autres programmes
- Il est nécessaire d'assembler différentes sources :
  - Plusieurs fichiers sources
  - Utilisation de macros, *etc.*

  ↪ Réalisé par le préprocesseur

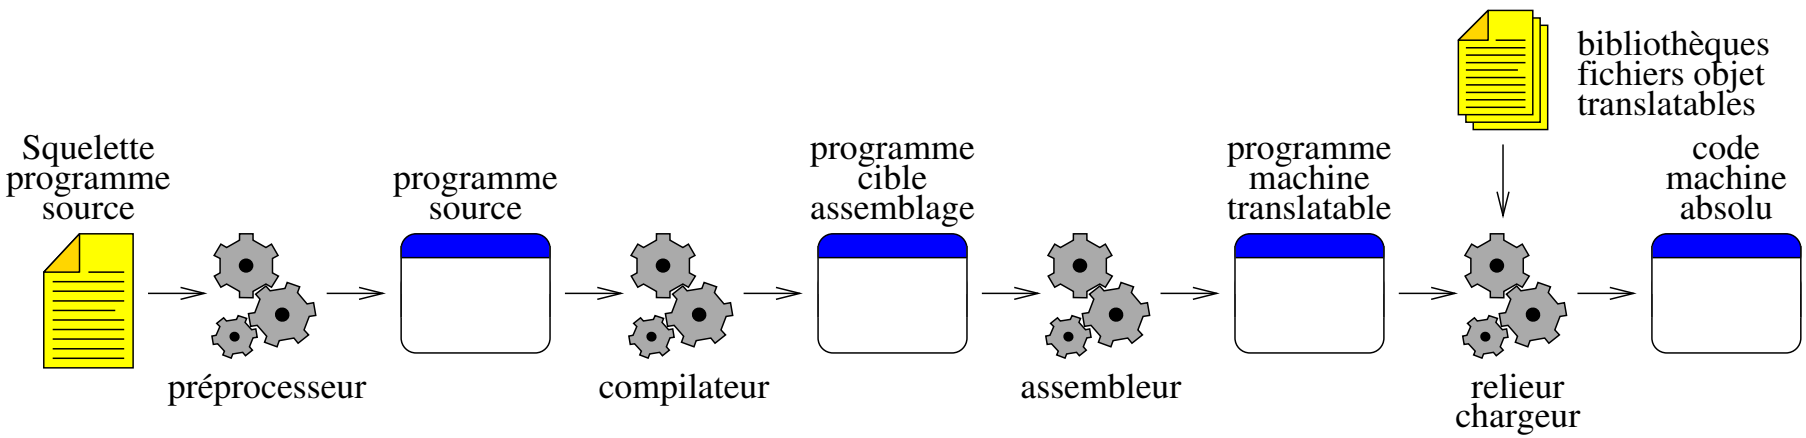

Les différentes phases de l'analyse

1. Analyse linéaire ou **analyse lexicale**
2. Analyse hiérarchique ou **syntaxique** ou **grammaticale**
3. Analyse sémantique

Analyse lexicale

- Son but est de reconnaître les **unités lexicales** (ou **lexèmes**)
- Exemples :
  - Les identificateurs et mots-clés du langage
  - Les opérateurs
  - Les valeurs

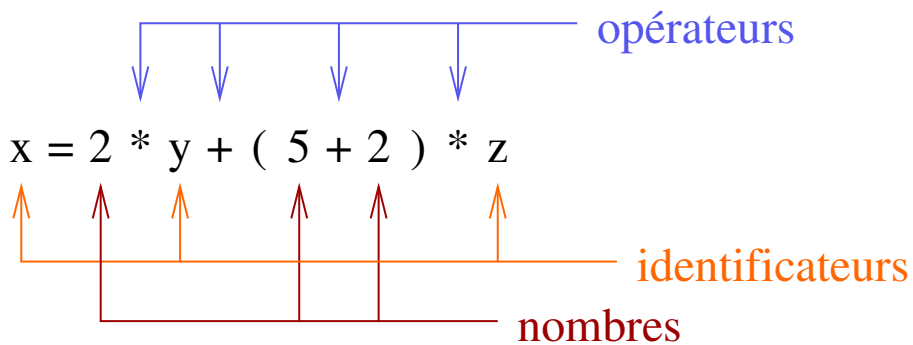

Analyse syntaxique (1/2)

- L'analyse syntaxique est appelée aussi **analyse grammaticale**
- Son but est de regrouper les unités lexicales en structures grammaticales
  $\hookrightarrow$ Généralement, elle génère des arbres syntaxiques
- Les structures grammaticales sont généralement hiérarchiques
  - Elles sont exprimées par des règles récursives
  - Exemple : on utilise des **grammaires**

Analyse syntaxique (2/2)

- Exemple de règles pour une expression :
  1. Tout *identificateur* est une expression
  2. Tout *nombre* est une expression
  3. Si exp_1 et exp_2 sont des expressions, il en est de même pour :
     - $exp_1 + exp_2$
     - exp_1 * exp_2
     - (exp_1)
- Exemple d'arbre syntaxique de $a = b * 2$:

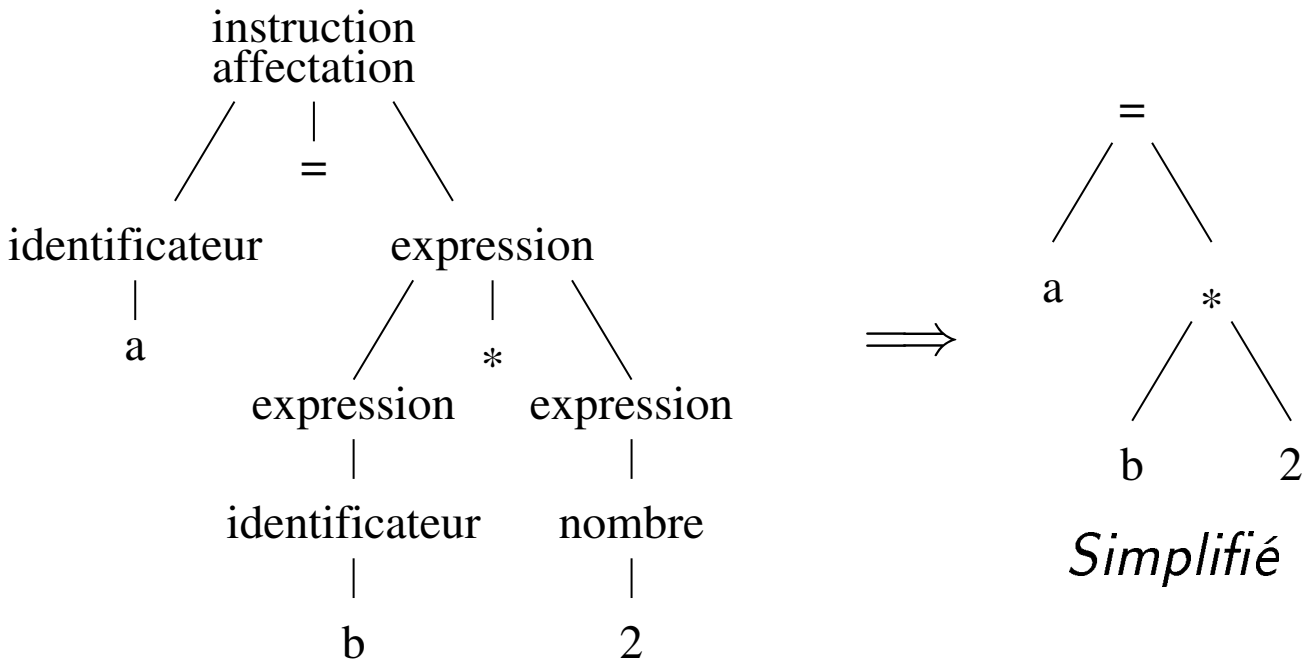

Analyse sémantique

- Son but est de vérifier si le programme source contient des erreurs sémantiques
  $\hookrightarrow$ Exemple : la vérification des types
- Elle exploite l'arbre syntaxique
- Exemple avec l'instruction précédente, si *a* est un réel et *b* un entier :

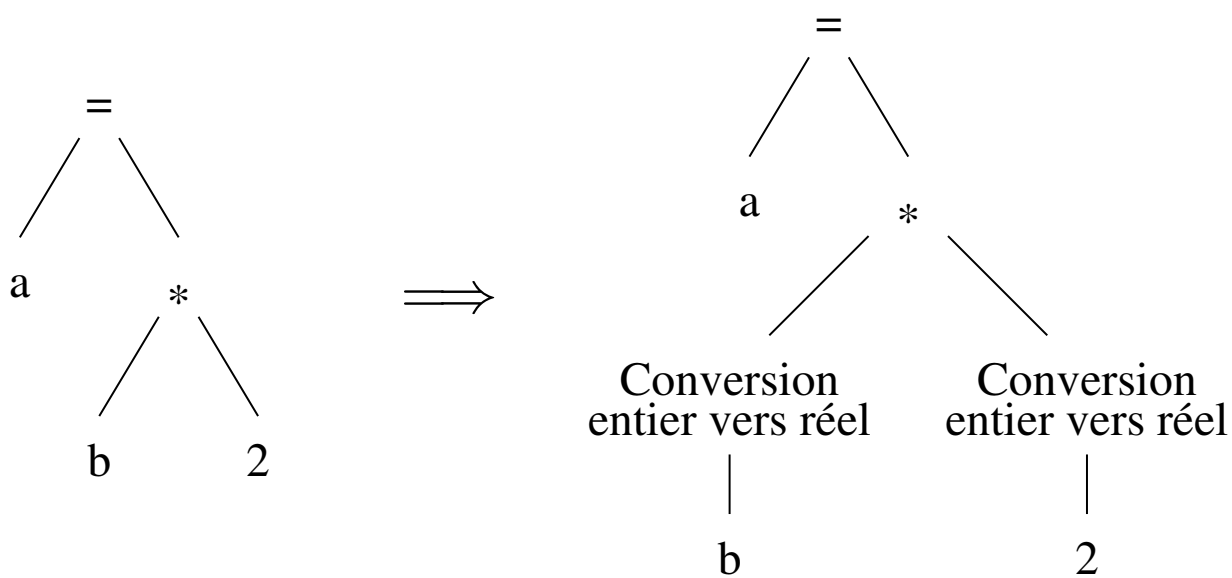

Les différentes phases de l'analyse

- La génération de code intermédiaire
- L'optimisation de code
- La génération de code

La génération de code intermédiaire

- Son but est de construire une représentation intermédiaire du programme source
- Deux propriétés pour cette représentation :
  - Elle doit être facile à produire
  - Elle doit être facile à traduire
- Exemple : le code à 3 adresses
  $\hookrightarrow$ C'est une séquence d'instructions dont chacune possède au plus 3 opérandes
- Elle nécessite :
  - D'utiliser des variables intermédiaires
  - De faire un choix sur l'ordre de calcul
- Exemple : $x = y + 2 * z$ (avec id1 = x, id2 = y et id3 = z)

```
tmp1 = 2
tmp2 = id3 * tmp1
tmp3 = id2 + tmp2
id1 = tmp3
```

L'optimisation de code

- Son but est d'améliorer le code intermédiaire :
  - Réduction du nombre de variables
  - Réduction du nombre d'instructions
- C'est l'une des phases les plus gourmandes en temps
- Exemple :

```
tmp1 = 2
tmp2 = id3 * tmp1
tmp3 = id2 + tmp2
id1 = tmp3
```

Avant

```
tmp1 = id3 * 2
id1 = id2 + tmp1
```

Après

La génération de code

- Son but est de produire du code machine translatable ou du code en langage d'assemblage
- Des emplacements mémoires sont choisis pour les variables
- La traduction des instructions du code intermédiaire en instructions machine nécessite d'assigner les variables aux registres
- Exemple :

```
MOVF id3, R2
MULF #2.0, R2
MOVF id2, R1
ADDF R2, R1
MOVF R1, id1
```

La table des symboles

- Lors de la compilation, il est nécessaire de collecter les informations (attributs) sur les identificateurs
  ↪ Le type, la valeur, l'emplacement mémoire, la portée
- La **table de symboles** est une structure de données contenant un champ pour chaque identificateur
- Les champs sont créés lors de l'analyse lexicale
- Les attributs sont ajoutés lors des phases suivantes
- La table permet aux différentes phases de trouver les informations nécessaires
  ↪ Exemple : le type lors de l'analyse sémantique

La gestion des erreurs

- Lors de chaque phase, des erreurs peuvent être générées
- Objectif de la gestion d'erreurs : traiter l'erreur pour poursuivre autant que possible
  $\hookrightarrow$ Il faut éviter l'arrêt dès la première erreur !
- Exemple d'erreurs :
  - Analyse lexicale : flot de caractères non reconnu
  - Analyse syntaxique : construction incorrecte
  - Analyse sémantique : type incorrect